

## Exercícios de estatística para análise de dados em HEP

*Professores:* Eliza Melo, Dilson Damião e Mauricio Thiel *Name:* Thiago de Andrade Rangel Monteiro

**EXERCÍCIO 1**

Para um ajuste linear da reta  $y(x) = ax + b$  aos  $N$  pares  $(x_i, y_i)$ , onde as incertezas são distintas, os resíduos são ponderados pela função  $\chi^2(a, b)$ , que deve ser minimizada. A função  $\chi^2$  é dada por:

$$\chi^2(a, b) = \sum_{i=1}^N \frac{[y_i - (ax_i + b)]^2}{\sigma_i^2} \quad (1.1)$$

Expandindo o quadrado, temos:

$$\chi^2(a, b) = \sum_{i=1}^N \left( \frac{y_i^2}{\sigma_i^2} - 2a \frac{x_i y_i}{\sigma_i^2} - 2b \frac{y_i}{\sigma_i^2} + a^2 \frac{x_i^2}{\sigma_i^2} + 2ab \frac{x_i}{\sigma_i^2} + b^2 \frac{1}{\sigma_i^2} \right) \quad (1.2)$$

Reescrevendo os termos em termos das médias ponderadas:

$$\chi^2(a, b) = \sum_{i=1}^N \frac{y_i^2}{\sigma_i^2} - 2a \sum_{i=1}^N \frac{x_i y_i}{\sigma_i^2} - 2b \sum_{i=1}^N \frac{y_i}{\sigma_i^2} + a^2 \sum_{i=1}^N \frac{x_i^2}{\sigma_i^2} + 2ab \sum_{i=1}^N \frac{x_i}{\sigma_i^2} + b^2 \sum_{i=1}^N \frac{1}{\sigma_i^2} \quad (1.3)$$

Para encontrar os valores de  $a$  e  $b$ , calculamos as derivadas parciais de  $\chi^2$  em relação a  $a$  e  $b$ , e igualamos a zero:

$$\frac{\partial \chi^2}{\partial a} = -2 \sum_{i=1}^N \frac{x_i (y_i - ax_i - b)}{\sigma_i^2} = 0 \quad (1.4)$$

$$\frac{\partial \chi^2}{\partial b} = -2 \sum_{i=1}^N \frac{(y_i - ax_i - b)}{\sigma_i^2} = 0 \quad (1.5)$$

Rearranjando as equações:

$$\sum_{i=1}^N \frac{x_i y_i}{\sigma_i^2} - a \sum_{i=1}^N \frac{x_i^2}{\sigma_i^2} - b \sum_{i=1}^N \frac{x_i}{\sigma_i^2} = 0 \quad (1.6)$$

$$\sum_{i=1}^N \frac{y_i}{\sigma_i^2} - a \sum_{i=1}^N \frac{x_i}{\sigma_i^2} - b \sum_{i=1}^N \frac{1}{\sigma_i^2} = 0 \quad (1.7)$$

Obtendo assim, um sistema de equações:

$$\begin{cases} \bar{x}^2 a + \bar{x} b = \bar{x} \bar{y} \\ \bar{x} a + b = \bar{y} \end{cases} \quad (1.8)$$

Resolvendo esse sistema para  $a$  e  $b$ , obtemos:

$$\begin{cases} a = \frac{\bar{x} \bar{y} - \bar{x} \bar{y}}{\bar{x}^2 - \bar{x}^2} \\ b = \bar{y} - a \bar{x} \end{cases} \quad (1.9)$$

**EXERCÍCIO 2**

Para calcular a seção de choque  $\sigma$ , usamos a seguinte fórmula:

$$\sigma = \frac{N_{\text{Total}} - N_{\text{background}}}{L} \quad (2.1)$$

onde:

- $N_{\text{Total}} = 2567$  é o número total de eventos observados,
- $N_{\text{background}} = 1223.5$  é o número de eventos de fundo esperado,
- $L = 25 \text{ fb}^{-1}$  é a luminosidade integrada.

Substituindo os valores na fórmula (2.1), obtemos:

$$\sigma = \frac{2567 - 1223.5}{25} = \frac{1343.5}{25} = 53.74 \text{ fb} \quad (2.2)$$

Para calcular a incerteza estatística, usamos a distribuição de Poisson. A incerteza estatística é dada por:

$$\sigma_{\text{stat}}^2 = \left( \frac{\sqrt{N_{\text{Total}}}}{L} \right)^2 + \left( \frac{\sqrt{N_{\text{background}}}}{L} \right)^2 \quad (2.3)$$

Utilizando nossos valores na equação (2.3), obtemos:

$$\sigma_{\text{stat}}^2 = \left( \frac{\sqrt{2567}}{25} \right)^2 + \left( \frac{\sqrt{1223.5}}{25} \right)^2 \quad (2.4)$$

$$\sigma_{\text{stat}} = \sqrt{6.07} \approx 2.46 \text{ fb} \quad (2.5)$$

Para o cálculo da incerteza sistemática, ela é dada por uma porcentagem da seção de choque e deve ser propagada diretamente. Para uma incerteza sistemática de 10%, temos:

$$\sigma_{\text{sist}} = 0.10 \times \sigma = 0.10 \times 53.74 = 5.37 \text{ fb} \quad (2.6)$$

Por fim, o valor da seção de choque com suas incertezas associadas é:

$$\sigma = 53.74 \pm 2.46_{\text{stat}} \pm 5.37_{\text{sist}} \text{ fb} \quad (2.7)$$

**EXERCÍCIO 3**

Para calcular quantos eventos esperados podem ser excluídos com 95% de confiança (C.L.) em uma análise onde a contagem de eventos segue uma distribuição de Poisson, consideramos que a probabilidade de observar  $k$  eventos quando o número esperado de eventos é  $\lambda$  é dada por:

$$P(k; \lambda) = \frac{e^{-\lambda} \lambda^k}{k!} \quad (3.1)$$

Neste caso, temos  $k = 0$ , então:

$$P(0; \lambda) = e^{-\lambda} \quad (3.2)$$

Para um nível de confiança de 95%, queremos encontrar o valor de  $\lambda$  tal que:

$$P(0; \lambda) \geq 0.05 \quad (3.3)$$

Isto implica que:

$$e^{-\lambda} \geq 0.05 \quad (3.4)$$

Tomando o logaritmo natural de ambos os lados, obtemos:

$$-\lambda \geq \ln(0.05) \quad (3.5)$$

Portanto:

$$\lambda \leq -\ln(0.05) \quad (3.6)$$

Calculando  $-\ln(0.05)$ :

$$-\ln(0.05) \approx 2.9957 \quad (3.7)$$

Assim, ao nível de confiança de 95%, podemos excluir um número esperado de eventos  $\lambda$  maior que aproximadamente 2.9957 eventos. Como o número esperado de eventos deve ser um número inteiro, podemos excluir até 3 eventos esperados com 95% de confiança. Com isso, temos que até 3 eventos esperados podem ser excluídos com esta análise com 95% de confiança.

#### EXERCÍCIO 4

A função  $\chi^2$  é definida como:

$$\chi^2 = \sum_{i=1}^N \frac{(y_i - f(x_i))^2}{\sigma_i^2}$$

onde:

- $y_i$  são os dados observados,
- $f(x_i)$  é o valor predito pelo modelo para  $x_i$ ,
- $\sigma_i$  é a incerteza associada aos dados observados.

#### ndf (graus de liberdade)

O número de graus de liberdade é dado por:

$$\text{ndf} = N - p$$

onde  $N$  é o número total de dados e  $p$  é o número de parâmetros ajustados no modelo.

### Propriedades da Distribuição $\chi^2$

A distribuição  $\chi^2$  com ndf graus de liberdade tem algumas propriedades importantes:

- **Média:** A média da distribuição  $\chi^2$  é igual a ndf:

$$E[\chi^2] = \text{ndf}$$

- **Variância:** A variância da distribuição  $\chi^2$  é  $2 \cdot \text{ndf}$ :

$$\text{Var}(\chi^2) = 2 \cdot \text{ndf}$$

### Ajuste do Modelo e $\chi^2/\text{ndf}$

- **Expectativa de  $\chi^2$ :** Quando o modelo se ajusta adequadamente aos dados, podemos esperar que:

$$E\left[\frac{\chi^2}{\text{ndf}}\right] = \frac{E[\chi^2]}{\text{ndf}} = \frac{\text{ndf}}{\text{ndf}} = 1$$

Isso significa que, em um ajuste ideal,  $\chi^2/\text{ndf}$  deve ser próximo de 1.

- **Desvio da Média:** Se  $\chi^2$  estiver significativamente maior que ndf, isso indicará que a soma dos quadrados dos resíduos é maior do que o esperado, sugerindo que o modelo não está capturando adequadamente a variabilidade dos dados. Neste caso,  $\chi^2/\text{ndf} > 1$ .
- **Desvio da Média Inferior:** Se  $\chi^2$  for significativamente menor que ndf, isso indicará que as incertezas foram superestimadas ou que o modelo é muito simples (subajuste). Neste caso,  $\chi^2/\text{ndf} < 1$ .